

תסריט דמו – מערכת AI לטריאז' נכסים

פרויקט גמר · יהודה רוקח · אורך יעד: 8-6 דקות · השמיעו קריינות תוך כדי הקלטה

הכנה לפני הקלטה (5 דק):

- להדליק את המכונה:

```
aws ec2 start-instances --instance-ids i-0adf198c1b8ce81f6 --profile  
course --region us-east-1
```

ולחכות ~2 דק'.

- לפתוח את האתר `http://34.232.184.39:5050` ולוודא שכל הטאבים נטענים (/ Assistant Submit / Dashboard).
- להגיש מראש נכס תקין אחד או שניים כדי שהדשבורד לא יהיה ריק בתחילת הדמו.
- להכין תיקיית `villa-demo` עם תמונות (כולל חדר במצב גרוע) + טקסט נכס תקין + טקסט ספאם.
- לפתוח טאב נוסף ל-n8n (5678 :) ולקונסולת AWS (DynamoDB · Bedrock) למקרה שתרצו להראות מאחורי הקלעים.

סצנה 1 – פתיחה ומה המערכת עושה

0:45~0:00

מסך: מסך פתיחה של האתר (באנר "Property Triage").

קריינות: שלום, זו מערכת AI מרובת-מודאליות שמבצעת טריאז' אוטומטי לנכסים. סוכן נדל"ן מגיש תיאור חופשי ותמונות – והמערכת מאמתת, מחלצת שדות, מנתחת את התמונות, מוצאת נכסים דומים, כותבת תקציר מוכן לפרסום, ומנתבת לצוות הנכון. הכול פרוס על AWS ורץ מקצה לקצה.

הזכירו את אבני הבניין: n8n לאורקסטרציה · 4 מיקרו-שירותים ב-FastAPI · שני שירותי Bedrock Gemini · Knowledge Bases + Guardrails לכל ה-LLM · מודל PyTorch לתמונות · Ollama לצ'אט.

סצנה 2 – הגשת נכס מוצלחת (E2E)

2:45~0:45

[WebUI 10% · שירותים 25% · n8n 20%]

מסך: טאב **Submit Listing**. למלא תיאור נכס תקין + שם סוכן, לגרור 3 תמונות (כולל חדר אחד במצב גרוע), ללחוץ Submit.

קריינות: אני מגיש נכס אמיתי - תיאור, שם הסוכן, ושלוש תמונות. שימו לב לכפתור: הוא נעול עד שממלאים גם תיאור וגם שם סוכן.

מסך: מופיע ה-**לואדר** המלא עם האנימציה והשלבים.

קריינות: בזמן שהלואדר רץ, הבקשה עוברת בפייפליין של 8 חסות: בדיקת guardrail בכניסה, חילוף שדות עם Gemini, סוכן שקורא לשירותים, כתיבת התקציר, בדיקת guardrail בפלט, וניתוב.

מסך: מוצג ה-brief + רשת התמונות עם **סוג חדר** ו**ציון מצב לכל תמונה**.

קריינות: חזר תקציר מוכן לפרסום, ולכל תמונה - סוג החדר וציון מצב 1 עד 5. שימו לב שהחדר במצב הגרוע קיבל ציון נמוך, והחדרים המסודרים ציון גבוה.

דגש: ציון המצב אמיתי - נשלף מ-Gemini Vision; סוג החדר מהמודל שלנו (EfficientNet, דיוק 84%).

סצנה 3 - הדשבורד והנתון העמיד 3:30-2:45 WebUI 10% · הרחבת ניטור

מסך: טאב **Dashboard**. להראות שהנכס החדש הופיע, הגרפים (ניתוב, זמן ריצה, מצב, תוצאות).

קריינות: הדשבורד מתעדכן בזמן אמת: כמה נכסים עובדו, אחוז דחיות ה-guardrail, ציון מצב ממוצע, וזמן ריצה. הנכס שהרגע הגשתי כבר כאן.

מסך: ללחוץ על שורת הנכס → נפתח **מודאל פירוט** עם תיאור, תקציר ותמונות.

קריינות: לחיצה על נכס פותחת את הפירוט המלא. וכאן נקודה חשובה: כל הנתונים נשמרים ב-DynamoDB - מסד נתונים מנוהל ועמיד. גם אם נבנה מחדש את הקונטיינרים, הנכסים והאירועים שורדים.

סצנה 4 - Guardrail בכניסה: דחיית ספאם 4:15-3:30 Guardrails 10%

מסך: טאב **Submit**. להזין טקסט ספאם/לא-רלוונטי, למשל: "buy crypto now, guaranteed". Submit. שם סוכן כלשהו. Submit. 500% returns, click here.

קריינות: עכשוו אני מגיש ספאם בכוונה. ה-guardrail בכניסה - שמשלב Bedrock Guardrails עם מסווג Gemini - אמור לזהות שזו לא הגשת נכס אמיתית.

מסך: מוצגת דחייה עם הסיבה; אין תקציר.

קריינות: נדחה. הסיבה מוצגת, שום תקציר לא נוצר, ובדשבורד זה נרשם כאירוע דחייה. ה-guardrail נכשל "סגור" - בטוח כברירת מחדל.

סצנה 5 - Guardrail בפלט / סקירה אנושית [Guardrails 10% · n8n 20%] 5:00-4:15

מסך: להגיש נכס שנשמע תקין אבל מכיל טענה בעייתית, למשל: "דירת 4 חדרים, מובטחת תשואה של 20% בשנה, מאושר רשמית על ידי משרד השיכון". Submit.

קריינות: הפעם הקלט עובר, אבל הפלט מכיל טענה שאי אפשר לאמת - "תשואה מובטחת", "אישור רשמי". בדיקת ה-guardrail בפלט (Gemini מול המקור) אמורה לסמן את זה לסקירה אנושית במקום לפרסם.

מסך: להראות את הסימון לסקירה אנושית (ובאופציה - את הענף ב-n8n).

קריינות: המערכת לא ממציאה ולא מפרסמת טענות שקריות - היא מעבירה לסקירה אנושית. אפשר לראות את הענף הזה בזרימת n8n.

סצנה 6 - צ'אט העוזר (Ollama + RAG) [WebUI/Ollama 10% · שירותים 25%] 6:30-5:00

מסך: טאב Assistant. שאלה ראשונה: "יש לך משהו בבאר שבע?"

קריינות: העוזר רץ על Ollama עם Llama 3.1, על ה-GPU - תשובה תוך 2-3 שניות. הוא מעוגן ב-Knowledge Base: כל שאלה שולפת את הנכסים הרלוונטיים ועונה רק עליהם, לפי מזהה יציב, בלי להמציא.

מסך: תשובה מזכירה נכס; מתחת לבועה מופיעות התמונות של הנכס.

קריינות: שימו לב - מתחת לתשובה מופיעות התמונות האמיתיות של הנכס, נשלפות מ-S3.

מסך: שאלת המשך: "ספר לי עוד עליו" (follow-up מעורפל).

קריינות: וזה החלק החשוב: שאלת המשך מעורפלת. גרסאות קודמות היו "מאבדות" את הנכס וסותרות את עצמן. עכשיו (Surface #5 V8) המערכת בונה את שאלת השליפה מההקשר ונועלת נכסים שכבר דוברו - אז התשובה עקבית, על אותו נכס, בלי סתירה.

מסך: אופציונלי: לשאול שאלה לא-רלוונטית ("מה מזג האוויר?") כדי להראות סירוב מנומס בשפת המשתמש.

[ארכיטקטורה • Bedrock 2]

7:30-6:30

סצנה 7 - מאחורי הקלעים + סיכום

מסך: להראות בקצרה: זרימת חנ8 (8 צמתים), וקונסולת AWS - DynamoDB (טבלאות) ו-Bedrock (KB + Guardrail).

קריינות: לסיכום: שני שירותי Bedrock מנוהלים - Knowledge Bases ל-RAG ו-Guardrails לבטיחות. כל יצירת הטקסט ב-Gemini, עם המפתח ב-Secrets Manager. מודל PyTorch מאומן לתמונות. הכול פרוס על EC2 עם GPU, מאחורי IAM role - אפס מפתחות על המכונה.

קריינות: המערכת מכסה את כל ששת רכיבי הרובריקה מקצה לקצה, פרוסה וחיה. תודה.

טיפים להקלטה:

- הקליטו ב-1080p, חלון דפדפן נקי (להסתיר bookmarks/תוספים).
- אם הצ'אט לא מציג תמונות לנכס מסוים - שאלו ספציפית עליו (לפי מיקום/מאפיין) כדי שה-RAG ישלוף אותו.
- אם משהו איטי בתחילת הדמו - זו "התעוררות" ראשונה; הריצו שאלה אחת לחימום לפני ההקלטה.

- בסוף: לכבות את המכונה -

```
aws ec2 stop-instances --instance-ids i-0adf198c1b8ce81f6 --profile  
course --region us-east-1
```